



**UNIVERSIDADE DO ESTADO DA BAHIA**

ALANA ABREU  
MARIA ISABEL NUNES VELOSO  
MATEUS OLIVEIRA  
RAFAEL ARGOLO

**Sistema de busca de informações de  
pesquisadores via FTS e LLM com  
indicadores**

Documento de Descrição do Sistema

CURSO: SISTEMAS DE INFORMAÇÃO  
DISCIPLINA: TÓPICOS ESPECIAIS EM  
ENGENHARIA DE SOFTWARE  
SEMESTRE: 2026.1

SALVADOR - BA

ABRIL, 2026

**Projeto:** Sistema de busca de informações dos pesquisadores baseado em Full-Text Search e LLM

**Sprint:** 1

**Versão:** 1.0

**Data:** 07/05/2026

**Autores:** Alana Abreu, Isabel Veloso, Mateus Oliveira, Rafael Argolo

## 1. Contexto e visão geral

O objetivo do trabalho é unificar conhecimentos de várias disciplinas envolvendo a concepção de um produto de software na área de Inteligência Artificial Generativa e Ciência de Dados, utilizando prototipação como mecanismo de especificação e validação técnica.

O sistema proposto implementa um pipeline de ETL para importar dados de currículos Lattes em XML (disponíveis localmente) para uma base relacional, e em seguida construir uma base vetorial para suportar busca semântica. Uma camada de back-end (API REST) expõe funcionalidades de busca e filtros para um front-end.

Além do banco de serviço usado pelo back-end, com Full-Text Search (FTS) e base vetorial, o sistema alimenta uma camada analítica (Gold) em um banco PostgreSQL separado, modelado dimensionalmente para consumo através do Power BI.

O sistema também considera indicadores/identificadores bibliométricos (~~conforme oficina de índices bibliométricos~~), priorizando aqueles viáveis com a base Lattes e com extração automatizada.

## 2. Problema

- 2.1. Informações de produção científica e técnica em XML são difíceis de consultar de forma consolidada.
- 2.2. A busca manual e navegação por currículos é lenta, pouco comparável e difícil de analisar historicamente.
- 2.3. Indicadores e qualificações de veículos (ex.: Qualis) não estão integrados ao currículo de maneira pronta para análise.

## 3. Objetivos

### 3.1. Objetivo geral

Construir um sistema que permita busca textual e semântica e análises sobre produções de pesquisadores a partir de XMLs Lattes, com enriquecimento por indicadores bibliométricos quando viável.

### 3.2. Objetivos específicos

- 3.2.1. Orquestração do ETL: XML Lattes → banco relacional (serviço).
- 3.2.2. Indexar textos para Full-Text Search (FTS) e busca semântica (vetores/embeddings).
- 3.2.3. Disponibilizar API REST para busca, filtros e acesso às entidades principais.
- 3.2.4. Construir front-end para consulta (pesquisa, filtros e detalhes).
- 3.2.5. Construir e manter uma base analítica (camada Gold) em PostgreSQL separado, com modelo dimensional para consumo em BI.
- 3.2.6. Incorporar indicadores: MVP com dados do XML (ORCID/DOI/ISSN) e Qualis via base externa; métricas como H-index/citações/JCR ficam como backlog.

## 4. Escopo

### 4.1. Escopo MVP (primeira entrega funcional)

- Extração de múltiplos XMLs de pesquisadores (base local).
- Persistência mínima no banco de serviço: pesquisador, produções, veículos (periódicos) e relações essenciais.
- Busca: FTS em títulos (mínimo) e busca semântica em títulos (mínimo).
- Filtros: por pesquisador, ano e tipo de produção; por Qualis quando associado por ISSN.
- Carga/atualização do PostgreSQL analítico (camada Gold) com fatos e dimensões básicas para consumo em BI.

### 4.2. Tipos de produção incluídos

Incluídos no MVP:

- Artigos em periódicos.
- Produção técnica (ex.: software, marca, patente), conforme disponibilidade no XML.

A avaliar/definir (não bloqueia o MVP):

- Livros.
- Capítulos.
- Trabalhos em eventos.
- Orientações, projetos, outras categorias presentes no XML.

Pendência (ESC-01): detalhar quais categorias entram no MVP e como serão tratadas no modelo de dados e na busca.

#### **4.3. Fora de escopo (por enquanto)**

- Integração garantida com bases pagas/fechadas (JCR/WoS/Scopus) sem confirmação de acesso.
- Extração estável de Google Scholar via scraping (alto risco).

## **5. Indicadores e identificadores bibliométricos**

### **5.1. Indicadores/IDs disponíveis no XML (MVP)**

- ORCID do pesquisador (quando presente).
- DOI da produção (quando presente).
- ISSN do periódico (quando presente).
- Outros metadados quando aplicável: ano, volume, páginas, título do periódico, etc.

Esses campos suportam deduplicação (por DOI), enriquecimento posterior por APIs e associação com Qualis via ISSN.

### **5.2. Indicadores a incorporar via base externa (MVP)**

#### **Qualis CAPES do periódico:**

- Estratégia: pipeline automatizado (Python ou Apache Hop) para obter/manter uma tabela local “Qualis Periódicos” e associar por ISSN.
- Observação: Qualis depende de área de avaliação e/ou quadriênio/versão, exigindo parametrização e registro de versão.

Pendência (IND-01): definir qual recorte de Qualis será usado (quadriênio/versão, área de avaliação, fonte e formato de obtenção).

### 5.3. Indicadores opcionais (Backlog)

- **Índice H / citações (ex.: Google Scholar):** automatização pode ser instável; só entrar se houver estratégia técnica aceitável.
- **JCR / Impact Factor:** depende de acesso institucional e/ou fonte disponível.

Proposta técnica: criar uma camada “Coletor de Métricas” plugável, priorizando coleta por DOI quando possível, registrando fonte, timestamp e confiabilidade.

## 6. Usuários e stakeholders

- Professor/orientador: valida entregas e escopo.
- Equipe: implementa ETL, indexação (FTS + vetores), API, front-end e camada analítica (Gold).
- Usuário final (acadêmico/gestão): consulta produção, indicadores e relatórios no BI.

## 7. Requisitos funcionais

- 7.1. **RF01:** Importar XMLs e persistir Pesquisadores e Produções no banco de serviço. [Arquitetura de Medalhão??]
- 7.2. **RF02:** Disponibilizar listagem e detalhe de pesquisador.
- 7.3. **RF03:** Busca FTS por título (mínimo).
- 7.4. **RF04:** Busca semântica por título (mínimo).
- 7.5. **RF05:** Filtros por ano, tipo de produção, pesquisador; e por Qualis quando disponível.
- 7.6. **RF06:** Popular e manter uma base analítica (Gold) em PostgreSQL separado, com tabelas dimensionais (fatos/dimensões) para consumo pelo BI.
- 7.7. **RF07:** Armazenar e expor identificadores (ORCID/DOI/ISSN) quando existirem.
- 7.8. **RF08 (MVP):** Associar Qualis ao periódico quando houver match por ISSN.

## 8. Requisitos não funcionais

- 8.1. **RNF01:** Reprodutibilidade por Docker.
- 8.2. **RNF02:** API REST documentada [Swagger??]
- 8.3. **RNF03:** Logs e rastreabilidade no ETL (falhas e registros rejeitados).
- 8.4. **RNF04:** Performance aceitável para busca em base local do projeto.
- 8.5. **RNF05:** Versionamento e rastreabilidade por sprints.

## 9. Dados, persistência e busca

- **PostgreSQL (Search/Backend DB):** entidades importadas do Lattes e estruturas de busca (FTS) e base vetorial (pgvector) para embeddings.
- **PostgreSQL (Analytics/Gold DB - separado):** modelo dimensional (fatos/dimensões) otimizado para consultas de BI e indicadores.
- **Integração entre camadas:** pipelines (Hop/Python) transformam dados do banco de serviço (e/ou staging) para o banco Gold.

## 10. Arquitetura macro (descrição)

- 10.1. **ETL Lattes:** XML → staging/validação → tabelas no PostgreSQL (banco de serviço).
- 10.2. **Indexação:** criação de índices FTS + geração de embeddings + armazenamento vetorial (pgvector) no banco de serviço.
- 10.3. **API REST:** endpoints de busca e filtros; acesso a entidades e metadados.
- 10.4. **Cargas analíticas (Gold):** pipelines constroem e atualizam o PostgreSQL analítico separado (dimensões/fatos).
- 10.5. **Business Intelligence:** Power BI conecta ao banco Gold (conexão direta) para relatórios e dashboards.

## 11. Privacidade/permissão de divulgação

Embora o XML contenha o atributo *PERMISSAO-DE-DIVULGACAO = Não*, o projeto irá ignorar essa restrição, pois é um trabalho acadêmico com base local fornecida para fins de disciplina.

## 12. Riscos e mitigação

- **Risco:** Qualis depende de recorte (área/quadriênio).
  - **Mitigação:** registrar pendência IND-01; implementar Qualis como tabela snapshot versionada.
- **Risco:** métricas externas (Scholar/JCR) sem acesso e com bloqueios.
  - **Mitigação:** backlog opcional; arquitetura plugável; iniciar com ORCID/DOI/ISSN + Qualis.
- **Risco:** heterogeneidade de campos nos XMLs.
  - **Mitigação:** schema tolerante à nulos; validação e logs no ETL.
- **Risco:** escopo grande (ETL + vetores + API + front + Gold/BI).
  - **Mitigação:** MVP bem recortado; pendências registradas.

### **13. Pendências / decisões abertas (registrar e acompanhar)**

- IND-01: Definir Qualis (recorte/área/quadriênio/fonte e forma de obtenção).
- ESC-01: Definir lista final de tipos de produção no MVP além de artigos e produção técnica.
- ~~ARQ-01 (opcional): Definir se embeddings serão gerados via serviço externo ou local (impacta custos/infra).~~

### **14. Critérios de sucesso do MVP**

- 14.1. XMLs importados com sucesso e consultáveis via API.
- 14.2. Busca FTS e busca semântica retornando resultados coerentes sobre títulos.
- 14.3. Filtros funcionando (ano, tipo, pesquisador; e Qualis quando disponível).
- 14.4. Base Gold em PostgreSQL separado populada e consultável pelo Power BI (conexão direta), com ao menos um relatório demonstrando métricas básicas.
- 14.5. Campos ORCID/DOI/ISSN persistidos quando existirem; Qualis associado quando houver match por ISSN (após definição IND-01).